

Instruções

1. Esta avaliação deve ser feita de duas 2 à 3 pessoas.
2. Data de entrega: **01/06/2026 até 18:59**. Trabalhos não podem ser entregues em atraso (sem possibilidade real de entrega posterior, sendo atribuído nota zero automaticamente).
3. Desenvolver um pipeline completo de processamento digital de imagens para segmentar automaticamente objetos de interesse em imagens reais, utilizando exclusivamente técnicas clássicas de processamento de imagens.
 - a. Filtragem no domínio da frequência;
 - b. Morfologia matemática;
 - c. Segmentação baseada em superpixels;
 - d. Pós-processamento e avaliação quantitativa;
4. A implementação deverá ser desenvolvida em Python. O uso de biblioteca e funções prontas será permitido desde que seja indicado no projeto. Porém, todos os códigos implementados estão passíveis de ser explicados, independente da origem. Para morfologia e segmentação, deverá apresentar sua solução sem o uso de funções prontas e únicas, trazendo uma implementação "from Scratch".
5. O sistema deve ser entregue funcionando corretamente.
6. Deve ser apresentado uma a solução:
 - Identificação do autor e do trabalho.
 - Enunciado do projeto
 - Explicação e contexto da aplicação para compreensão do problema tratado pela solução
 - Desenvolvimento
 - Códigos importantes da implementação.
 - Resultados obtidos com a implementação
 - Análise e discussão sobre os resultados finais (inclusive de problemas)
7. Deve ser disponibilizado os códigos da implementação juntamente com a relatório (salvo o caso da disponibilidade em repositório aberto do aluno, que deve ser fornecido o link). O repositório deve estar aberto do momento da entrega em diante, sendo que o professor não responsabiliza caso o projeto não esteja disponível para consulta no momento da correção, sendo do(s) aluno(s) essa responsabilidade de manter disponível.
8. A não entrega e apresentação do trabalho acarretará nota zero para todos os integrantes. Todos os integrantes deverão ter conhecimento de todas as partes da implementação. O integrante que não apresentar, terá sua nota zerada no quesito apresentação. Todos os alunos deverão responder os questionamentos na apresentação, porém fica a cargo do professor escolher um representante que explicar pelo grupo.
9. Postar Slide+Relatório+Respositório/Colab/Código no material da disciplina.
10. Cada grupo terá de 10 minutos para apresentar seu desenvolvimento, seguido por 5 minutos de perguntas. O processamento estará passível de ser testada com qualquer imagem no momento da apresentação.

Descrição do projeto a ser desenvolvido

No cenário do processamento de imagens, a segmentação desempenha um papel crucial ao permitir a decomposição de uma imagem em regiões significativas e distintas. Essa técnica fundamental é essencial para uma variedade de aplicações, desde reconhecimento de objetos e rastreamento de movimento até diagnóstico médico e análise de cena. A segmentação de imagens visa identificar e delinear objetos ou regiões de interesse dentro de uma imagem, fornecendo uma representação mais estruturada e compreensível dos dados visuais.

Está atividade avaliativa aborda os principais conceitos por trás da segmentação de imagens junto a um pipeline de processamento, explorando técnicas clássicas e recentes. Ao compreendermos os princípios e as inovações na segmentação de imagens, podemos destacar seu papel vital no processamento de imagens e suas diversas aplicações em áreas como visão computacional, medicina, agricultura, entre outras.

Projeto

Os alunos deverão propor e implementar um pipeline para identificar automaticamente regiões de interesse em imagens reais. O desafio está em ajustar as etapas do fluxo para o dataset escolhido, exigindo experimentação e análise crítica. Cada conjunto de alunos deverá justificar:

- Quais técnicas foram utilizadas;
- A ordem do pipeline;
- Os parâmetros escolhidos;
- O impacto de cada etapa no resultado final.

Pipeline Base (Flexível)

1. Pré-processamento: Envolve Conversão de espaço de cor (RGB, HSV, LAB ou escala de cinza), normalização e Equalização de histograma (opcional).
2. Filtragem no Domínio da Frequência: Filtro passa-baixa, passa-alta, passa-faixa ou rejeita-faixa.
3. Segmentação: aplicação de um dos algoritmos propostos.
4. Morfologia Matemática: Envolve erosão, dilatação, abertura, fechamento, reconstrução morfológica e preenchimento de buracos.
5. Avaliação: IoU (Intersection over Union), Dice Coefficient, etc.

Obs: Restrição Importante – É proibido o uso de Deep Learning, U-Net, YOLO, Modelos pré-treinados e Prompt para geração automática integral do código.

Algoritmos de Segmentação Propostos:

- Superpixels SLIC: algoritmo simples, rápido e muito utilizado para geração de superpixels
 - Link 1: <https://ieeexplore.ieee.org/document/6205760>
 - Link 2: <https://infoscience.epfl.ch/entities/publication/2dd26d47-3d00-43eb-9e31-4610db94a26e>
 - DOI: doi.org/10.1109/TPAMI.2012.120
- Segmentação por Entropia Local: fundamenta o uso de medidas estatísticas e texturais, incluindo entropia
 - Link 1: <https://ieeexplore.ieee.org/document/4309314>
 - DOI: doi.org/10.1109/TSMC.1973.4309314
- Morphological Reconstruction: fundamental para remover artefatos, preencher regiões e preservar formas importantes
 - Link 1: <https://ieeexplore.ieee.org/document/217222>
 - DOI: doi.org/10.1109/83.217222
- Watershed com Marcadores Superpixel: técnica clássica que pode usar superpixels como marcadores
 - Link 1: <https://perso.telecom-paristech.fr/bloch/ANIM/CorpsCalleux/Meyer1994.pdf>
 - DOI: doi.org/10.1016/0165-1684(94)90060-4
- Otsu por Superpixel: método clássico e fácil de aplicar sobre estatísticas extraídas dos superpixels.
 - Link 1: <https://ieeexplore.ieee.org/document/4310076>
 - DOI: doi.org/10.1109/TSMC.1979.4310076
- Algoritmo alternativo
 - Indicado pelos alunos
 - Indicar qual artigo foi usado

Datasets (Escolha 1 Dataset)

- Blood Cell Segmentation – <https://www.kaggle.com/datasets/paultimothymooney/blood-cells>
 - Desenvolver um método capaz de identificar e segmentar automaticamente as células presentes em imagens microscópicas coloridas.
 - Deve gerar uma máscara binária contendo apenas as regiões correspondentes às células de interesse.
 - Desafios: presença de ruído e artefatos provenientes da aquisição microscópica, variação significativa de cor entre diferentes tipos celulares, células parcialmente sobrepostas e objetos com tamanhos e formatos distintos.

- Métricas: Dice Coefficient, IoU e/ou Contagem de objetos segmentados.
- Skin Lesion Segmentation (ISIC) – <https://challenge.isic-archive.com/data/>
 - Desenvolver um algoritmo para delimitar automaticamente a região da lesão em imagens dermatoscópicas
 - Deve ser gerado uma máscara binária representando exclusivamente a lesão.
 - Desafios: baixo contraste entre a lesão e a pele saudável, Presença de pelos, bolhas e artefatos escuros, iluminação não uniforme e bordas irregulares e pouco definidas
 - Métricas: Dice Coefficient, IoU e/ou sensibilidade e especificidade.
- Segmentação de Grãos Agrícolas – <https://www.kaggle.com/datasets/ddsssss/seed-images>
 - Separar automaticamente grãos individuais em imagens adquiridas sobre fundo uniforme.
 - Deve gerar uma máscara binária em que pixels pertencentes aos grãos sejam representados por valor 1 e pixels do fundo sejam representados por valor 0
 - Desafios: grãos tocando uns aos outros, variação de tamanho e orientação, reflexos, ruído de fundo
 - Métrica: IoU, Dice Coefficient e contagem de segmentos.
- Plant Seedlings Classification – <https://www.kaggle.com/competitions/plant-seedlings-classification>
 - Desenvolver um algoritmo para delimitar automaticamente as folhas e caules das plantas
 - Deve gerar uma máscara binária em que pixels pertencentes à plântula (folhas e caule visível) sejam marcados com valor 1 e pixels correspondentes ao solo e ao fundo sejam marcados com valor 0.
 - Desafios: variação de iluminação, presença de solo texturizado, plantas com diferentes formatos, regiões verdes no fundo, sobreposição parcial, reflexos especulares e estruturas finas
 - Métrica: IoU, Dice Coefficient e contagem de segmentos.
- NEU Surface Defect Database – http://faculty.neu.edu.cn/songkechen/zh_CN/zdylm/263270/list/index.htm
 - Detectar regiões correspondentes a arranhões, trincas ou manchas em superfícies metálicas ou têxteis
 - Gerar uma máscara binária contendo exclusivamente as regiões defeituosas, tais como trincas, riscos, porosidades e manchas
 - Desafios: baixo contraste, textura complexa, defeitos pequenos, variações de iluminação e ruído de aquisição
 - Métricas: IoU e Dice Coefficient.

Critérios de Avaliação

Critério	Peso
Implementação correta	30%
Uso ou não da frequência	10%
Uso ou não de morfologia	10%
Segmentação com superpixels	20%
Qualidade dos resultados	10%
Discussão crítica	20%

As notas levam em conta qualidade da apresentação também. Com isso, a demonstração de domínio técnico na exposição da solução é essencial e corresponde à metade da nota de cada critério. Todos os alunos devem apresentar a parte técnica, sendo que a apresentação de introdução ao problema não vale como exposição técnica.

Obs: Comece sempre pelo problema, logo, escolha um dataset e depois pense nas técnicas para resolver o problema.